

UNIVERSIDADE DO OESTE DE SANTA CATARINA

Campus de Joaçaba
Área das Ciências Exatas e Tecnológicas

PROJETO FINAL
CONSTRUÇÃO DE UM LARGE
LANGUAGE MODEL
FROM SCRATCH

Curso: Engenharia de Computação
Componente Curricular: Inteligência Artificial e Sistemas Inteligentes
Professor: Kleyton Hoffmann
Período Letivo: 2026/2

Joaçaba – SC
2026

Sumário

1	Apresentação	2
2	Objetivos	3
2.1	Objetivo Geral	3
2.2	Objetivos Específicos	3
3	Metodologia de Desenvolvimento	3
3.1	Leitura Orientada	4
3.2	Glossário Técnico	4
3.3	Quiz	4
3.4	Implementação	5
3.5	Experimentação	5
3.6	Análise dos Resultados	5
4	Cronograma do Projeto LLM	5
5	Entregáveis	7
6	Avaliação	7
7	CrITÉrios Técnicos de Avaliação	7
8	Uso de Ferramentas de Inteligência Artificial	8
9	Resultado Final Esperado	9
10	Política de Atrasos	9
11	Referência Principal	10

1 Apresentação

O Projeto Integrador tem como objetivo proporcionar aos acadêmicos uma experiência prática e incremental de construção de um *Large Language Model* (LLM), permitindo compreender os principais componentes computacionais envolvidos no funcionamento dos modelos de linguagem contemporâneos.

A atividade será desenvolvida ao longo do semestre tomando como referência principal a obra:




Figura 1: RASCHKA, Sebastian. *Build a Large Language Model (From Scratch)*. Manning Publications.

Diferentemente da utilização exclusiva de modelos previamente treinados ou serviços disponibilizados por meio de APIs, o projeto terá como princípio a implementação progressiva dos principais componentes de um modelo de linguagem.

Durante o desenvolvimento serão abordados processamento e representação de texto, tokenização, embeddings, mecanismos de atenção, arquitetura Transformer, construção de uma arquitetura GPT, treinamento, geração de texto e estratégias de *fine-tuning*.

O projeto será desenvolvido paralelamente aos demais conteúdos do componente curricular, funcionando como atividade transversal de integração entre programação, aprendizado de máquina, redes neurais artificiais e aprendizado profundo.

O projeto pode ser desenvolvido em duplas, mas muitas das avaliações parciais ocorrerá de forma individual.

A linguagem de programação utilizada pelo autor é o Python, então seguiremos da mesma forma.

2 Objetivos

2.1 Objetivo Geral

Compreender os fundamentos computacionais dos modelos de linguagem por meio da implementação incremental dos principais componentes de uma arquitetura baseada em Transformer.

2.2 Objetivos Específicos

Ao final do projeto, espera-se que o acadêmico seja capaz de:

- compreender o fluxo completo de desenvolvimento de um modelo de linguagem;
- implementar mecanismos de tokenização e preparação de dados textuais;
- compreender e implementar representações vetoriais e embeddings;
- implementar mecanismos de atenção e *self-attention*;
- compreender a arquitetura Transformer utilizada em modelos GPT;
- implementar os principais componentes de uma arquitetura GPT;
- compreender o processo de treinamento de um modelo de linguagem;
- analisar funções de perda e o comportamento do treinamento;
- realizar geração de texto utilizando o modelo desenvolvido;
- compreender estratégias de utilização de modelos pré-treinados e *fine-tuning*;
- analisar criticamente resultados, limitações e comportamento do modelo desenvolvido.

3 Metodologia de Desenvolvimento

O projeto será desenvolvido de forma incremental durante o semestre. Cada etapa estará associada a capítulos selecionados da obra de referência e será organizada segundo o seguinte fluxo:

**Leitura → Glossário → Quiz → Implementação → Experimentação →
Análise**

Cada etapa deverá contribuir para a construção progressiva do modelo final. Consequentemente, os componentes implementados nas etapas anteriores poderão ser reutilizados e integrados às etapas posteriores.

3.1 Leitura Orientada

Antes de cada etapa de implementação, os acadêmicos deverão realizar a leitura dos capítulos ou seções indicados.

A leitura deverá priorizar a compreensão dos conceitos, da arquitetura dos algoritmos e das relações existentes entre os diferentes componentes do modelo.

3.2 Glossário Técnico

Para cada capítulo estudado deverá ser elaborado um glossário contendo os principais conceitos, técnicas, componentes, parâmetros e termos técnicos introduzidos.

O objetivo do glossário não será simplesmente traduzir os termos da língua inglesa, mas registrar de forma sintética seu significado e sua função no contexto dos modelos de linguagem.

Cada entrada deverá, sempre que aplicável, apresentar:

- termo original;
- tradução ou equivalente técnico em português;
- definição;
- função no modelo de linguagem;
- relação com outros conceitos;
- exemplo conceitual, matemático ou computacional.

O glossário será cumulativo. Dessa forma, ao final do semestre, os acadêmicos terão construído um glossário técnico dos principais conceitos utilizados na implementação de modelos de linguagem.

3.3 Quiz

Serão realizados quizzes periódicos, preferencialmente individuais, destinados a acompanhar a leitura e verificar a compreensão conceitual dos conteúdos estudados.

Os quizzes poderão contemplar conceitos, interpretação de código, estruturas computacionais, parâmetros, operações matemáticas e análise do comportamento dos componentes implementados.

3.4 Implementação

Cada etapa envolverá uma atividade prática relacionada ao conteúdo estudado.

A implementação deverá demonstrar domínio dos conceitos apresentados no capítulo correspondente. A simples reprodução integral de códigos disponíveis no livro, repositórios públicos ou outras fontes não será considerada suficiente para caracterizar o desenvolvimento da atividade.

3.5 Experimentação

Sempre que aplicável, deverão ser realizados experimentos envolvendo alterações em parâmetros, configurações ou dados utilizados pelo modelo.

Os experimentos deverão permitir observar o impacto dessas alterações sobre o comportamento, desempenho ou custo computacional da solução.

3.6 Análise dos Resultados

Os resultados obtidos deverão ser analisados tecnicamente.

O acadêmico deverá demonstrar capacidade de interpretar os resultados e relacioná-los aos conceitos estudados, evitando limitar o relatório à apresentação de códigos, gráficos ou valores numéricos sem discussão.

4 Cronograma do Projeto LLM

Data	Sprint	Capítulo	Atividades
30/07	Sprint 0	Preparação	Apresentação do projeto, organização dos grupos, instalação do ambiente Python, Git, PyTorch, estrutura do repositório e cronograma geral.
06/08	Sprint 1	Capítulo 1	Introdução aos Large Language Models. Leitura orientada, elaboração do glossário, Quiz 1 e mapa conceitual da arquitetura GPT.

Data	Sprint	Capítulo	Atividades
13/08	Sprint 1	Capítulo 1	Discussão técnica, apresentação dos conceitos fundamentais e entrega da atividade da Sprint 1.
20/08	Sprint 2	Capítulo 2	Tokenização, vocabulário, Token IDs e preparação dos conjuntos de dados.
27/08	Sprint 2	Capítulo 2	Embeddings, Positional Embeddings, DataLoader, experimentos e entrega da Sprint 2.
03/09	Sprint 3	Capítulo 3	Introdução aos mecanismos de Attention. Implementação de Self-Attention.
10/09	Sprint 3	Capítulo 3	Scaled Dot-Product Attention, Causal Attention e experimentação.
17/09	Sprint 3	Capítulo 3	Multi-Head Attention, experimentos comparativos e documentação técnica.
24/09	Sprint 3	Capítulo 3	Integração dos mecanismos de atenção, Quiz 3 e entrega da Sprint 3.
01/10	—	-	Participação no Simpósio das Engenharias. Sem entrega do Projeto LLM.
08/10	—	Avaliação	Avaliação A1/2 (Lógica Fuzzy). Sem atividades do Projeto LLM.
15/10	Sprint 4	Capítulo 4	Arquitetura GPT, Transformer Block, Layer Normalization e Feed Forward Network.
22/10	Sprint 4	Capítulo 4	Residual Connections, integração dos blocos Transformer e construção do modelo GPT.
29/10	Sprint 4	Capítulo 4	Inferência, geração de texto, experimentos, documentação e entrega da Sprint 4.
05/11	Sprint 5	Capítulo 5	Treinamento do modelo, função de perda, otimizadores e ciclo de treinamento.
12/11	Sprint 5	Capítulo 5	Avaliação do treinamento, geração de texto, experimentos com hiperparâmetros e documentação.

Data	Sprint	Capítulo	Atividades
19/11	Sprint 6	Capítulos 6 e 7	Fine-Tuning, adaptação para tarefas específicas, integração do projeto e preparação da apresentação final.
26/11	—	Avaliação	Avaliação A1/3 (Redes Neurais). Sem atividades do Projeto LLM.
03/12	Entrega Final	Projeto Completo	Entrega do repositório final, glossário consolidado e relatório técnico.

5 Entregáveis

Durante o semestre, cada grupo deverá manter um repositório contendo a evolução do projeto. O repositório deverá permitir acompanhar a evolução incremental do projeto e reproduzir os principais experimentos realizados.

6 Avaliação

O Projeto LLM compõe a avaliação A1/1 do componente curricular.

A avaliação será processual e considerará tanto o desenvolvimento realizado durante o semestre quanto o resultado final apresentado.

Critério	Peso
Quizzes individuais	15%
Implementações intermediárias e glossários	25%
Modelo LLM integrado	25%
Experimentação e análise dos resultados	15%
Documentação técnica	10%
Apresentação e arguição individual	10%
Total	100%

7 Critérios Técnicos de Avaliação

As implementações serão avaliadas considerando os seguintes aspectos:

Critério	Descrição
Correção técnica	Os algoritmos e componentes deverão estar implementados corretamente e apresentar comportamento compatível com os objetivos da atividade.
Compreensão	Os integrantes deverão demonstrar capacidade de explicar o funcionamento dos componentes desenvolvidos.
Experimentação	Deverão ser realizados experimentos envolvendo parâmetros, configurações ou dados relevantes para o componente estudado.
Análise	Os resultados deverão ser interpretados tecnicamente e relacionados aos conceitos estudados.
Integração	Os componentes desenvolvidos deverão ser progressivamente integrados ao projeto.
Glossário	O glossário deverá apresentar precisão conceitual, terminologia adequada e relação dos conceitos com a arquitetura estudada.

8 Uso de Ferramentas de Inteligência Artificial

É permitida a utilização de ferramentas de Inteligência Artificial Generativa como apoio ao desenvolvimento do projeto, incluindo auxílio na interpretação de erros, documentação, explicação de conceitos e sugestões de implementação.

Entretanto, todo código, documentação, análise ou resultado entregue deverá ser compreendido pelos integrantes responsáveis pela atividade.

Durante as avaliações, apresentações ou arguições, o professor poderá solicitar que qualquer integrante:

- explique trechos do código;
- descreva o funcionamento de determinado componente;
- interprete uma equação ou operação utilizada;
- altere parâmetros do modelo;
- modifique parte da implementação;
- execute testes adicionais;
- interprete resultados experimentais;

- relacione diferentes componentes da arquitetura.

A incapacidade de demonstrar domínio técnico sobre o material entregue poderá resultar em redução individual da nota.

9 Resultado Final Esperado

Ao término do projeto, espera-se que os acadêmicos tenham implementado e compreendido um pipeline contendo os principais componentes de um modelo de linguagem:

**Texto → Tokenização → Token IDs → Embeddings → Positional
Embeddings → Multi-Head Attention → Transformer Blocks → GPT →
Treinamento → Geração de Texto**

O objetivo do projeto não será desenvolver um modelo capaz de competir com modelos comerciais de larga escala, mas compreender experimentalmente os fundamentos computacionais envolvidos na construção e no treinamento de modelos generativos baseados na arquitetura Transformer.

O modelo deverá possuir dimensões compatíveis com os recursos computacionais disponíveis, priorizando compreensão arquitetural, implementação, experimentação, análise dos resultados e domínio técnico dos conceitos.

10 Política de Atrasos

Política de Entrega e Atrasos

As entregas deverão ser realizadas até a data e horário estabelecidos no cronograma oficial da disciplina.

A avaliação do projeto pressupõe o desenvolvimento incremental das atividades. Dessa forma, o cumprimento dos prazos faz parte dos critérios de organização, planejamento e gestão do projeto.

As seguintes regras serão adotadas:

Entregas realizadas até 24 horas após o prazo terão desconto de 10% da nota da atividade correspondente. Entregas realizadas entre 24 e 72 horas após o prazo terão desconto de 30% da nota. Entregas realizadas após 72 horas poderão ser aceitas apenas para fins de acompanhamento da aprendizagem, recebendo nota zero, salvo situações excepcionais devidamente justificadas e aceitas pelo professor. O atraso em uma sprint não altera os prazos das sprints subsequentes, permanecendo o cronograma oficial inalterado. A ausência de entrega de uma sprint poderá comprometer o desenvolvimento das etapas seguintes, uma vez que o projeto possui caráter incremental.

Situações excepcionais (problemas de saúde, participação em eventos institucionais autorizados, falhas técnicas comprovadas ou outras circunstâncias relevantes) poderão ser analisadas individualmente pelo professor mediante documentação ou justificativa apresentada em tempo hábil.

11 Referência Principal

RASCHKA, Sebastian. *Build a Large Language Model (From Scratch)*. Manning Publications.